



June. 28 / 2024

제3차 미니프로젝트 발표 @ 연세IT미래교육원 (702호)

[DAPT] 공간 빅데이터를 활용한 도시 양극 화 분석

Contents

I. 프로젝트 개요

II. 팀원 소개 및 역할

III. 개발 과정

IV. 결론

도시 양극화란? GPT에게 물어봤다!



“도시 내 또는 도시 간에 발생하는
경제적, 사회적, 공간적 격차가 심화되는 현상
을 의미”


도시 양극화란?



도시 양극화는 도시 내에서 경제적, 사회적, 문화적 격차가 극단적으로 심화되는 현상을 말합니다. 이는 주로 고소득층과 저소득층 간의 격차가 커지면서 발생합니다. 도시 양극화의 주요 원인은 다음과 같습니다:

- 경제적 불평등:** 부유한 지역과 가난한 지역 간의 경제적 격차가 심화되면서, 소득과 자산의 불평등이 커집니다.
- 교육 기회 격차:** 고소득층이 더 좋은 교육 기회를 얻고, 저소득층은 상대적으로 열악한 교육 환경에 놓이게 됩니다.
- 주거 문제:** 부유한 지역은 고급 주택과 편의시설이 집중되는 반면, 저소득층은 주거 환경이 열악한 지역에 살게 됩니다.
- 고용 기회 불평등:** 고소득층이 양질의 일자리를 더 쉽게 얻는 반면, 저소득층은 저임금, 비정규직 등에 종사하게 됩니다.
- 사회적 이동성 저하:** 사회 계층 간 이동이 어려워지면서, 빈곤이 대물림되고 계층 이동이 제한됩니다.

왜 양극화 인가?



“사회에서 지역소멸 및 지방소멸 문제를 심각하게 인식 중,
이에, 지역 소멸위기 해소에 도움이 되고자 함”

- 분석 대상 : 충청권 도시들 (세종, 대전, 충북, 충남)

인구 유입 중



선택 이유



“비수도권이지만
사람이 몰리는 도시(세종, 대전)

와

지방소멸위기 도시가 다수 속

해 있어 양극화를 분석하기 전

일부 소멸 위 기



도시 양극화를 어떻게 분석할까?

역시...  GPT에게 물어봤다!

경제적 격차

“부유한 지역과 빈곤한
지역 간의 소득 차이,
고용 기회, 경제적 자원
의 불균형”

사회적 격차

“교육, 보건, 안전,
생활 수준 등 사회
적 자원의 접근성
차이”

공간적 격차

“주거지, 상업지구, 공
공 인프라의 분포 불
균형 및 도시 계획의
차별”

• 통계 자료

생산가능 인구비율

범죄율

아파트 매매
실거래 가격지수

월평균 소득 분포

비교
분석




결론

생산가능 인구비율, 아파트매매실거래 가격지수, 월평균 소득 분포를 봤을 때 양극화를 잘 보여준다는 것을 알 수 있음

그 중에서 우리는 아파트매매실거래 가격지수를 종속변수로 선택하여 예측, 분석하기로 함

세종시,대전시,충북,충남의 월평균 소득 분포 비교



왜 아파트 가격을 주요 변수로 선정 했나?

도시의 상대적인 부유함과 빈곤함(낙후정도)을 잘 보여주는 변
수는 아파트가격이라고 판단.

지역의 월평균 소득 상승에 대부분을 기여하는 차지하는 중산
층, 상류층의 주거주지로서 편리함을 주는 아파트 혹은 고급 아
파트가 선택되고, 저소득층은 아파트 진입이 어렵기 때문.

변수 선택법

후진제거법 (Backward Elimination)

처음엔 32개의 변수를 사용하여 훈련시켰으나, 과대적합 발생

- ① 해결하기위해 차원축소 (변수 제거, 주성분 분석)
- ② 7개 변수 선정

독립변수 (최종 선정)

지역별 인구 이동 데이터
(총전입, 총전출
시도간전입, 시도간전출)

PIR지수

종합부동산 세율
(중위값)

아파트매매거래량

아파트 매매수급동향

대통령 지지율

주택 담보 대출 금리

소비자물가지수

종속변수

지역별 아파트
매매 실거래지수 데이터

제외변수 및 사유

지역별 1인 가구 수 ◆ 높은 상관관계를 확인했으나 월별데이터가 없어서 빠른 반영 불가

국회의원 의석수 우위 (보수 vs 진보) ◆ One-Hot Encoding하여 넣어봤으나, 예측율 감소

주택구입부담지수 ◆ 월별 데이터가 아닌 분기 데이터만 확보 가능, 빠른 반영 불가
◆ PIR지수와 사용되는 변수가 겹침

기준금리 ◆ 0.86으로 서로 강한 양의 상관관계를 보임으로, 다중공선성 문제 해소를 위해
실거래지수와 상관관계가 높은 주택담보대출금리 채택

LIR지수 ◆ 둘이 서로 다른 측면에서 주택 시장의 *가용성(affordability)을 평가하나,
0.96으로 상관관계가 매우 높아 실거래지수와 상관관계가 높은 PIR지수 채택
* 일반적으로 개인이나 가구가 주택을 구매하거나 임대하는 데 필요한 비용을 수용할 수 있는 정도

Data Analytics Professional Team

Seong



데이터 크롤링
데이터 전처리
자료탐색

SHIN



DB 설계 및 구축
데이터 전처리
자료탐색

Park



계획 수립 및 총괄
ML모델 구축
데이터 전처리

Lee



백엔드 구축
데이터 시각화
자료분석

Oh



백엔드 구축
데이터 시각화
자료탐색




데이터 수집

Case ① 크롤링 (자동 수집)



API
(데이터 URL)



크롤링
(URL기반 수집)

Case ② 리서치 (직접 수집)



API
(이용 불가)



웹페이지 접속
(직접 수집)



데이터 수집

HF 한국주택금융공사
주택금융연구원

Gallup 한국갤럽

일부 변수 크롤링 실패 문제 해결:

주택금융연구원, 한국갤럽 데이터 등 크롤링 실패한

데이터에 대한 크롤링 모듈 설계 및 개발 예정



데이터 전처리

방법① '시점'열을 기준으로 데이터 프레임 결합

시점(기준열)	인구이동데이터	PIR지수
2013.01	100000	100
2013.02	200000	110
2013.03	300000	120
...	...	...
2023.12	1000000	140

② 스케일링

Min-Max 스케일링

$$x_{scaled} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Robust 스케일링

$$X_{scaled} = \frac{X_i - \min(X)}{\max(X) - \min(X)}$$



모델 구축

(기존 모델)


이동 데이터
8 가지 변수

차원 축소

4가지 변수

충전입
충전출
순이동
시도간전입
시도간전출
시도내이동-시군구내
시도내이동-시군구간 전입
시도내이동-시군구간 전출

충전입
충전출
시도간전입
시도간전출



과대 적합 발생!

(결과)



Bad!

추가 독립 변수의 필요성 인지!

전국 아파트 매매 실거래 지수에 대한 예측률을
확보하여, 지역별 데이터와 혼합하여 성능 향상 도모


① Min-Max

데이터 분포를 유지하면서
스케일을 조정하기 위해
선택

② Robust

상자수염그림

이상치 발견되는 변수들 확인



결과

결정계수 **0.92~0.93**
성능향상을 위해 다항식 변환을
각각 적용했음

Degree 2
결정계수는 향상,
but 과대적합 발
생

Degree 3, Degree 4
성능악
화

과대적합 해결 시도

L1(Lasso)

- 1) 결정계수 : 0.983
 - 2) Train MSE : 2.7359 / Test MSE:3.9460
 - 3) K-Fold 평균 MSE:5.2754
- * **과대적합 다소 개선**

L2(Ridge)

- 1) 결정 계수 : 0.978
 - 2) Train MSE:3.6552 / Test MSE:5.1577
 - 3) K-Fold 평균 MSE:6.3747
- * 예측력 감소, 평균 MSE 증가 = **성능 감소**

ElasticNet(L1 + L2)

- 1) 결정계수 : 0.948
 - 2) Train MSE:15.2791 / Test MSE:12.4829
 - 3) K-Fold 평균 MSE:20.2519
- * 결정 계수 감소, 훈련/테스트 MSE 증가,
평균 MSE 증가 = **성능 감소**

PCA(주성분 분석)

- 1) 결정계수: 0.912
 - 2) Train MSE:4.4733 / Test MSE:22.9941
 - 3) K-Fold 평균 MSE:388.6948
- * 결정계수 감소, 과대적합 여전,
K-Fold 평균 MSE 급상승 -> **성능 악화**

추후 개발 방향

백선형 회귀 모델 / 딥러닝모
델 구현

채택


Robust + L1 선택
(가장 우수!!)

검증

세종시 실거래지수 예측치 시
연

향후 방향성 (여전히 개선 필요!!!)

“추후 의사결정나무, RandomForest, XGBoost 등 비선형 회귀 모델들과 딥러닝 알고리즘에 테스트하여 성능 향상을 도모할 예정”






데이터 시각화 & 서비스 구축



데이터 시각화 & 서비스 구축

- ① 인구순이동 : 2013 ~ 2023년 합산 기준 전국이동인구 순이동 BAR CHART 및 지도 구현
- ② 실거래지수 및 실업률 : 2023년 대전/세종/충북/충남 실거래 가격지수 및 실업률 BAR CHART(이미지) 삽입
- ③ 범죄율 및 생산가능인구 : 2023년 대전/세종/충북/충남 범죄율 및 생산가능인구 BAR CHART(이미지) 삽입



matplotlib



Streamlit



데이터 시각화 & 서비스 구축



Network URL: <http://192.168.71.220:8501>

1. 종합

- 1) 지도 구현 : 대전, 세종, 충남, 충북 4개 지역 색깔로 표기
- 2) 아파트 실거래가격지수 LINE CHART 구현 : 대전, 세종, 충남, 충북 4개 지역
- 3) 월평균 소득구간 비율 BAR CHART로 구현 : 대전, 세종, 충남, 충북 4개 지역

2. 실거래지수 예측모델(데모버전)

- 1) 좌측 메뉴에서 "지역", "시작연월", "종료연월" 선택
- 2) 선형회귀 머신러닝 알고리즘을 통해서 미래 아파트 실거래지수 예측

3. 부동산매물 추천모델(데모버전)

- 1) 좌측 메뉴에서 "지역", "선호인프라" 선택
- 2) 선형회귀 머신러닝 알고리즘을 통해서 개인 맞춤형 서울 아파트 매

DB설계 및 구축

모든 데이터를 DB에 적재완료

가족(Family)		
PK	fm_single	-1~4인가구
PK	fm_two	-4인가구
PK	fm_three	-4인가구
PK	fm_four	이상
PK	fm_fourmore	

실거래지수(Transaction_Price_index)		
PK	tp_Transaction_Price_index	실거래지수
FK	as_saving	날짜
FK	iv_date	

독립변수(Independent_variable)		
FK	Transaction_Price_index	
PK	President_support_rate	
PK	iv_date	
PK	PIR_national_index	
PK	Consumer_price_index	
PK	realestate_tax_for_individual	
PK	total_numberof_transaction	
PK	mortgage_loan	
PK	Supply_demands_trend	
PK	inflow_total	
PK	net_movement	
PK	outflow_total	

- 실거래지수
- 대통령 지지율
- 날짜(2013~2023 년월)
- PIR 지수
- 소비자 물가지수
- 종합부동산세(개인)
- 총거래량
- 주택담보대출
- 매매수급동향
- (총)전입
- (총)전출
- 순이동

- 나이
- 자산
- 대출
- 가족 구성원 수

나이(Age)		
PK	a_10s	INTEGER(2)
PK	a_20s	
PK	a_30s	
PK	a_40s	
PK	a_50s	
PK	a_60s	
PK	a_70s	
PK	a_80s	
PK	a_90s	
PK	a_100s	INTEGER(3)

Customer(고객)		
PK	cs_age	CHAR(3)
FK	as_savings	CHAR(10)
FK	as_loan	CHAR(10)
FK	fm_single	CHAR(1)
FK	fm_two	
FK	fm_three	
FK	fm_four	
FK	fm_fourmore	
FK	as_investment	

인프라_접근성(infrastructure-accessibility)		
PK	ia_transport	INTEGER
PK	ia_safety	
PK	ia_health	
PK	ia_education	
PK	ia_leisure	
FK	cs_age	CHAR(3)

- 교통
- 안전강도
- 건강교육
- 여가

자산(Assets)		
PK	as_savings	CHAR(10)
PK	as_loan	
PK	as_investment	
FK	cs_age	INTEGER

- 예금
- 대출
- 현금화 가능한 투자금 (전세금/주식/펀드/코인)



DB설계 및 구축

부동산 매물의 가격 예측을 위한 데이터 DB를 통
해 추출

① 예제 SQL 쿼리 작성

머신러닝 데이터 선정

예시 : 2014.01 이전 데이터 + 인프라 수준 1등급 + 용산구

```
SELECT * FROM parameter where Pm_Date < 2014.01;
```

```
select inflow_total, outflow_total, net_movement from seoul where Io_Date < 2014.01;
```

```
select Subway, Primary_School, Middle_School, High_School, General_Hospital, Supermarket, Park  
from fancy where district = 'yongsan-gu';
```

```
SELECT
```

```
p.*,  
s.inflow_total, s.outflow_total, s.net_movement,  
f.Subway, f.Primary_School, f.Middle_School, f.High_School, f.General_Hospital, f.Supermarket, f.Park  
FROM parameter p
```

```
JOIN seoul s ON p.Pm_Date = s.Io_Date
```

```
JOIN fancy f ON f.district = 'yongsan-gu'
```

```
WHERE p.Pm_Date < '2014-01-01' AND s.Io_Date < '2014-01-01';
```



② 데이터 추출

outflow_total	net_movement	Subway	Primary_School	Middle_School	High_School	General_Hospital
151771	-14152	981	1261	140	159	1200
131098	-11357	981	1261	140	159	1200
142141	-8773	981	1261	140	159	1200
109528	-6519	981	1261	140	159	1200
126101	-6930	981	1261	140	159	1200

DB설계 및 구축


파이썬 머신러닝 학습을 위한 데이터 Export 및
 ※ 모델 학습

추후 DB에서 데이터를 추출하는 모듈을 작성할 예

③ CSV로 Export

정

④ 모델 적용을 위한 데이터



파일 이름(N): train_data.csv

파일 형식(T): CSV (*.csv)

플더 숨기기

저장(S) 취소

```
Pm_Date,Transaction_Price_index,President_support_rate,PIR_national_index,Consumer_price_index,real estat
2013.12,85.7,54,5.1,93.229,1.0,67883,3.74,"94.53",137619,151771,-14152,981,1261,140,159,1200,1400,1600
2013.11,85.7,54,5.04,93.116,1.0,61844,3.77,"95.61",119741,131098,-11357,981,1261,140,159,1200,1400,1600
2013.10,85.7,54,5.09,93.134,1.0,65871,3.81,"95.66",133368,142141,-8773,981,1261,140,159,1200,1400,1600
2013.09,85.2,60,5.08,93.419,1.0,39801,3.82,"92.23",103009,109528,-6519,981,1261,140,159,1200,1400,1600
2013.08,84.6,60,5.09,93.238,1.0,30794,3.8,"89.56",119171,126101,-6930,981,1261,140,159,1200,1400,1600
2013.07,84.3,60,5.15,92.909,1.0,25079,3.77,"90.41",118420,127308,-8888,981,1261,140,159,1200,1400,1600
2013.06,83.7,51,5.52,92.71,1.0,94647,3.73,"92.1",115773,124523,-8750,981,1261,140,159,1200,1400,1600
2013.05,84.0,51,5.62,92.823,1.0,64538,3.77,"93.34",130619,138830,-8211,981,1261,140,159,1200,1400,1600
2013.04,83.8,51,5.65,92.823,1.0,55442,3.86,"92.34",134581,144586,-10005,981,1261,140,159,1200,1400,1600
2013.03,83.5,42,5.53,92.952,1.0,47375,3.97,"88.63",138507,146220,-7713,981,1261,140,159,1200,1400,1600
2013.02,83.1,42,5.49,93.038,1.0,34089,4.06,"87.21",150805,155528,-4723,981,1261,140,159,1200,1400,1600
2013.01,83.0,42,5.35,92.728,1.0,16968,4.17,"86.1",118477,123006,-4529,981,1261,140,159,1200,1400,1600
```

DBMS를 러신머닝 모델구축에 사용해야 하는 이유(1)

SCHEMAS

Filter objects

- haksa
- ▼ infrastructure
 - ▼ Tables
 - busan
 - cheap
 - chungnam
 - chungbuk
 - daegu
 - daejeon
 - fancy
 - jeonnam
 - jeonbuk
 - jeju
 - incheon
 - gyeongbuk
 - gwangju
 - gangwondo
 - parameter
 - sejoong

DBMS

서울시 고가 아파트-인프라 데이터 –

fancy

district	Subway	Primary_School	Middle_School	High_School	General_Hospital
yongsan-gu	302	769	772	741	1900
eunpyeong-gu	363	462	763	893	2600
jonglo-gu	499	756	1200	1200	1000
jung-gu	310	1417	286	224	1800
junglang-gu	845	601	856	491	860
seongdong-gu	288	428	840	336	1900

서울시 저가 아파트 - 인프라 데이터 –

cheap

district	Subway	Primary_School	Middle_School	High_School	General_Hospital
yongsan-gu	981	1261	140	159	1200
eunpyeong-gu	413	367	344	929	3000
jonglo-gu	588	1000	382	365	430
jung-gu	514	524	139	183	1500
junglang-gu	575	733	983	857	342
seongdong-gu	528	706	619	572	2300

DBMS를 러신머닝 모델구축에 사용해야 하는 이유(2)

SCHEMAS

Filter objects

- ▶ haksa
- ▼ infrastructure
 - ▼ Tables
 - ▶ busan
 - ▶ cheap
 - ▶ chungnam
 - ▶ chungbuk
 - ▶ daegu
 - ▶ daejeon
 - ▶ fancy
 - ▶ jeonnam
 - ▶ jeonbuk
 - ▶ jeju
 - ▶ incheon
 - ▶ gyeongbuk
 - ▶ gwangju
 - ▶ gangwondo
 - ▶ parameter
 - ▶ sejoong

DBMS

실거래지수에 기여도가 높은 변수 –
parameter

Pm_Date	Transaction_Price_in	President_support_ra	PIR_national_index	Consumer_price_index
2013.01	83.0	42	5.35	92.728
2013.02	83.1	42	5.49	93.038
2013.03	83.5	42	5.53	92.952
2013.04	83.8	51	5.65	92.823
2013.05	84.0	51	5.62	92.823
2013.06	83.7	51	5.52	92.71


인구이동 데이터 –

Io_Date	inflow_total	busan_inflow_total	net_movement
2013.01	39348	40048	-700
2013.02	42857	42807	50
2013.03	39546	41004	-1458
2013.04	40603	41548	-945

데이터 추출 형식 (SQL을 활용할 계획)

활용 예시)

- 1) 2013~2014 데이터 + 인프라 수준 1등급(서초구) + 서초구(인구이동 데이터)
가격변동폭이 가장 드라마틱 했던 2019~2023
- 2) 2019~2023 데이터 + 인프라 수준 1등급(용산구) + 용산구(인구이동 데이터)
- 3) 2013~2023 데이터 + 인프라 수준 5등급(서울시) + 서울시(인구이동 데이터)



결과 세종시 실거래지수 예측 치

1) 결정계수: 0.968

2) Train MSE:6.3516 / Test MSE:15.6219

3) 평균 MSE:24.9379

- 13.01~23.11까지의 데이터를 넣어 훈련시킨 후,

23년 12월의 실거래지수를 예측

- 실제 실거래지수 : 122.0

- 모델 예측 실거래지수 : 130.33

* 많은 성능 개선이 필요

1. 아파트 가격 예측 서비스

가설 : 인프라 수준이 높을 수록 부동산 가격의 상승을
추래


조사!

(범위) 서울시 구 아파트

(대상) 최고가 아파트, 최저가 아파트

(확인 사항) 아파트-인프라 간 거리

결과: 고가의 아파트일 수록 생활인프라가 가까운가? 가깝다!



아파트-인프라 간 평균거리를 계산해서 이를 기준으로 인프라 등급표 작성



2. 추후 발전 방향

시나리오 기반 매물 추천 솔루션 (가상인물 김모 씨 사례)



기준1



선호 인프라



“저는 직장인이고 아내와 같이 살
집을
구하고 있으며, 지하철역이 가까
운 곳을
선호하며 러닝을 즐겨 해서 집 주
공원이 있으며 좋을 것 같아요.”

기준2

무주택자, 나이, 자산규모, 가구 인원, 소득
수준

무주택자, 나이 : 20~30대 , 자산 규모 : 5
억 원

주거 인원 : 2명, 연봉 : 5천 만원

2. 추후 발전 방향

고객 상황별 데이터 수집 및 인프라 접근성 등급 분류

인프라	1등급	2등급	3등급	4등급	5등급
지하철	425.08	464.81	504.54	544.27	584
초등학교	586.36	608.03	629.7	651.37	673.04
중학교	447.76	520.2	592.64	665.08	737.52
고등학교	747.2	767.99	788.78	809.57	830.36
종합병원	1306.96	1364.48	1422	1479.52	1537.04
대형마트	890.44	983.55	1076.66	1169.77	1262.88
공원	974.44	1129.12	1283.8	1438.48	1593.16

고객	나이	희망 금액	가구 인원	선호인프라-1지망	선호인프라-2지망
신정윤님	20	150,000,000	1	지하철	대형마트
박주찬님	30	300,000,000	3	초등학교	종합병원
오승필님	40	500,000,000	2	대형마트	지하철
성우진님	50	1,000,000,000	2	고등학교	공원
이의재님	60	650,000,000	4	종합병원	대형마트
파이썬님	70	450,000,000	2	공원	지하철
딤러닝님	80	300,000,000	2	종합병원	대형마트
판다스님	90	2,000,000,000	1	공원	대형마트

End of Page

- 감사 합 니 다-

